

CORPORACIÓN UNIVERSITARIA MINUTO DE DIOS – UNIMINUTO

Desarrollo de un modelo predictivo para la detección de anomalías de autenticación mediante la metodología CRISP-DM en el sector salud

Javier Eduardo Gomez Ovalle

Juan Camilo Ballares Díaz

Minería de Datos

NRC DE LA MATERIA

NOMBRE DEL PROFESOR

Ibagué, Tolima. Abril de 2026

Contenido

1. Introducción	4
2. Fase 01: Comprensión del negocio	5
2.1. Antecedentes de la organización	5
2.2. Planteamiento del problema	6
2.2.1. Vector 1: Fuerza bruta y Credential Stuffing	7
2.2.2. Vector 2: Suplantación Silenciosa (Anomalía de Viaje Imposible)	7
2.3. Objetivo general	8
2.4. Objetivos específicos	8
2.4.1. Criterios de éxito cuantitativos	9
3. Fase 02: Comprensión del negocio	10
3.1. Fuente 1: RBA Dataset (Risk-Based Authentication Dataset, Kaggle)	10
3.2. Fuente 2: Catálogo IP–País–ASN (IPinfo Free IP to Country ASN Database)	11
3.3. Fuente 3: Maestro de Personal Hospitalario (empleados.csv, sintético)	12
4. Fase 03: Preparación de los datos	13
4.1. Objetivo fase 03	13
4.2. Alcance y límites fase 03	13
4.3. Caracterización inicial del RBA Dataset	14
4.4. Selección del subconjunto de usuarios	15
4.5. Generación del maestro sintético de empleados	16
4.6. Enriquecimiento mediante IPinfo	17
4.7. Tratamiento temporal y de variables de autenticación	18
4.7.1. Login Timestamp	18
4.7.2. Login Successful	18
4.8. Ingeniería de características	19
4.9. Validaciones de calidad	20
4.10. Control de fuga de información (target leakage)	20
4.11. Arquitectura modular	22
4.12. Principios SOLID aplicados	23
4.13. Pruebas realizadas	24
4.14. Equivalencia entre pipeline legacy y el modular	25

4.15.	Diagnóstico de Account Takeover (ATO Diagnóstico de Account Takeover (ATO)	27
4.15.1.	Diagnóstico 1: ejecutado, con resultados completos.....	27
4.15.2.	Diagnóstico 2: script entregado, ejecución pendiente de reporte	28
4.16.	Situación actual de la fase.....	29
4.17.	Decisiones pendientes.....	31
4.18.	Conclusiones parciales.....	33



UNIMINUTO
Corporación Universitaria Minuto de Dios
Educación de calidad al alcance de todos
Vigilada MinEduación

VERY GOOD



1. Introducción

2. Fase 01: Comprensión del negocio

2.1. Antecedentes de la organización

El presente proyecto se desarrolla sobre el estudio de caso de un Hospital Clínico Privado de Alta Complejidad el cual maneja diferentes tipos de servicios de salud (IPS), también cuenta con una unidad de cuidados intensivos (UCI), entre otras.

Este hospital al ser de cuarto y quinto nivel maneja grandes volúmenes de información de salud protegida (PHI), ya que el hospital trabaja 24/7, con turnos rotativos y médicos que trabajan en el área de urgencia en horas de la madrugada, esto quiere decir que la atención no se interrumpe aunque se realice en horarios no convencionales, esto representa un gran riesgo a nivel de datos y a nivel de acceso a la información, ya que un acceso ilegítimo fuera de horario y un acceso legítimo también fuera de horario, pasaría de forma inadvertida, esto lo hace un blanco fácil para cualquier atacante.

2.2. Planteamiento del problema

A partir de reportes previos del equipo de seguridad de la información, se ha identificado que el vector de ataque más probable y de mayor impacto, no corresponde a una explotación de una vulnerabilidad del software, sino mas bien al abuso de credenciales legítimas.

El planteamiento anterior corresponde correctamente con el framework MITRE ATT&CK, en este se hace énfasis en la técnica T1078(Valid accounts), aquí se documenta como una vía de acceso inicial que, al usar credenciales validas, es capaz de pasar por todos los controles perimetrales tradicionales tales como (firewalls, IPS/IDS basados en firmas), esto obliga a que se realice un enfoque de detección basado en el comportamiento del usuario (UEBA, que por sus siglas: “User and Entity Behavior Analytics”).

Con toda la información anterior, se llegó a la conclusión de que se tienen que monitorear 2 vectores de compromiso de autenticación.

2.2.1. Vector 1: Fuerza bruta y Credential Stuffing

Este vector corresponde al acceso mediante una prueba iterativa de credenciales, estos pueden ser mediante diccionario (fuerza bruta clásica) o por reutilización de pares-contraseña (Credential Stuffing). Para reconocer este evento, se hace mediante una serie muy repetitiva de eventos con el campo “Login Succesful = FALSE”, estos normalmente realizados desde una misma IP o desde IPs perteneciente a IABs conocidos.

2.2.2. Vector 2: Suplantación Silenciosa (Anomalía de Viaje Imposible)

Este vector corresponde al escenario más sigiloso de todos ya que el atacante obtiene una credencial valida desde el inicio, esto mediante phishing o comprada a un IAB, y la utiliza sin generar fallos de autenticación, ya que el campo “Login Succesful” siempre será = TRUE las reglas simples basadas en conteo de intentos no detectaran nada anómalo. Para este caso se usará un indicador operativo geográfico-temporal, es decir, si el mismo “USER ID” se autentica de forma exitosa desde Bogotá y 30 minutos después de autentica exitosamente desde Paris, en este caso siendo una ubicación físicamente inalcanzable en ese lapso, se configurará la anomalía conocida como Impossible travel.

2.3. Objetivo general

Desarrollar un modelo predictivo basado en minería de datos para identificar inicios de sesión sospechosos en el hospital, ayudando a detectar de forma automática cuándo un atacante externo está intentando suplantar la identidad de un empleado.

2.4. Objetivos específicos

- Fusionar tres fuentes de datos independientes: el registro histórico de autenticaciones (RBA Dataset), el catálogo de geolocalización IP-País (IPinfo) y el maestro sintético de personal hospitalario en un único archivo de trabajo en Python utilizando la librería Pandas.
- Crear variables de comportamiento basadas en ciberseguridad, como el número de intentos fallidos para detectar "fuerza bruta" y la ubicación geográfica para detectar "viajes imposibles".
- Entrenar un algoritmo de Árbol de Decisión que sea fácil de entender y graficar, permitiendo explicar de manera clara y visual por qué el sistema clasifica un acceso como normal o como ataque.
- Evaluar el rendimiento del modelo utilizando métricas específicas para datos desbalanceados, esto con el fin de garantizar una alta efectividad en la detección de amenazas reales sin ir a saturar el sistema con falsas alarmas.

2.4.1. Criterios de éxito cuantitativos

En un Dataset de autenticación real, los eventos anómalos representan una fracción minúscula del total (normalmente inferior al 2-3% de la clase positiva), es por esto que usar una métrica como Accuracy no sería viable ya que un modelo tan trivial que clasifique todo como “normal”, alcanzaría una exactitud por encima del 97% sin detectar ni un solo ataque.

- Recall (Sensibilidad) ≥ 0.80 sobre la clase minoritaria (anómala): un Recall bajo implica un alto número de Falsos Negativos, es decir, ataques reales que el sistema clasifica como tráfico legítimo. En el contexto de protección de PHI, un Falso Negativo es el error de mayor costo de negocio, pues equivale a una brecha de datos no detectada.
- F1-Score ≥ 0.80 sobre la clase minoritaria: al ser la media armónica entre Precisión y Recall, este indicador garantiza que la mejora del Recall no se logre a costa de saturar al equipo del SOC con Falsos Positivos (fatiga de alertas), un fenómeno ampliamente documentado como causa de baja adopción de sistemas de detección en centros de operaciones de seguridad.

3. Fase 02: Comprensión de los datos

3.1. Fuente 1: RBA Dataset (Risk-Based Authentication Dataset, Kaggle)

Este es el núcleo del proyecto, es un histórico de eventos de autenticación web con más de 33 millones de filas, las cuales corresponden a un servicio de inicio de sesión con instrumentación de riesgo (Risk-Based Authentication).

Campo	Tipo	Rol en el proyecto
Login Timestamp	Fecha/Hora	Base para los indicadores de fuera de horario y viaje imposible.
User ID	Texto/Numérico	Llave foránea hacia el maestro de empleados.
IP Address	Texto (IPv4/IPv6)	Llave de cruce (tras conversión a entero) hacia el catálogo IPinfo.
Country	Texto	País de acceso reportado por el proveedor de autenticación; se contrastará contra el país resuelto vía IPinfo como control de calidad cruzado.
Round-Trip Time [ms]	Numérico	Variable auxiliar de latencia de red; potencial indicador indirecto de uso de VPN o proxy.
Device Type / User Agent String	Texto	Insumo para detectar cambios abruptos de dispositivo o navegador en un mismo 'User ID'.
Login Successful	Booleano	Base directa del indicador de fuerza bruta / Credential Stuffing (ráfagas de False).
Is Attack IP / Is Account Takeover	Booleano	Variables de referencia (ground truth) provistas por el Dataset original, utilizadas para validar y, en su defecto, complementar la variable objetivo-construida por el estudiante.

3.2. Fuente 2: Catálogo IP–País–ASN (IPinfo Free IP to Country ASN Database)

Esta tabla corresponde al catálogo público de geolocalización de rangos de direcciones IP, a diferencia de una tabla convencional, esta no contiene una columna de IP convencional sino mas bien un rango de IPs definidos por un limite inferior y uno superior.

Campo	Tipo	Descripción
start_ip	Texto (IP)	Dirección IP inicial del rango.
end_ip	Texto (IP)	Dirección IP final del rango.
country	Texto	Código ISO 3166 del país (p. ej., CO, US).
country_name	Texto	Nombre completo del país.
continent / continent_name	Texto	Código y nombre del continente.
asn	Texto	Número de Sistema Autónomo (Autonomous System Number).
as_name	Texto	Nombre de la organización propietaria del AS.
as_domain	Texto	Dominio oficial de dicha organización.

3.3. Fuente 3: Maestro de Personal Hospitalario (empleados.csv, sintético)

Debido a la inexistencia de un directorio activo (Active Directory) público y real de una institución hospitalaria, se construirá un maestro sintético al cual se le asignaran roles y un perfil de hospital privado coherente, pero sin omitir el importante detalle de que los valores de “USER ID” deben coincidir de forma exacta con un subconjunto de los “USER ID” reales.

Campo	Tipo	Descripción
User ID	Texto	Llave primaria; extraída directamente del RBA Dataset (no generada).
Nombre_Completo	Texto	Nombre sintético generado con Faker, sin valor analítico propio (anonimización por diseño).
Rol_Hospitalario	Categórico	Cargo dentro del hospital; variable clave para la hipótesis de variabilidad horaria por rol.
Pais_Residencia	Categórico	País de residencia declarado del empleado; base de la variable de discordancia geográfica.
Ciudad_Base	Categórico	Ciudad de residencia declarado del empleado; base de la variable de discordancia geográfica.
Turno_Asignado	Categórico	Franja horaria oficial de trabajo; contraste directo contra el indicador de acceso fuera de horario.
Estado_Cuenta	Categórico	Activo/Inactivo; un acceso exitoso proveniente de una cuenta 'Inactivo' es, por definición de negocio, un evento de máxima prioridad.
Fecha_Ingreso	Fecha	Fecha oficial de vinculación del empleado; permite determinar la antigüedad de la cuenta y validar la regla de negocio frente a intentos de acceso previos a la contratación formal.

4. Fase 03: Preparación de los datos

4.1. Objetivo fase 03

El objetivo principal de esta fase es Transformar las tres fuentes de datos en un único Dataset (dataset_final_modelo.csv) limpio, integrado, enriquecido y con características de comportamiento construidas, listo para alimentar un Árbol de Decisión en la Fase 4, esto corresponde exclusivamente a la preparación de los datos mas no de modelado.

4.2. Alcance y limites fase 03

En esta fase se respeta de forma estricta la frontera metodológica que impone CRISP-DM entre la Preparación de los Datos y el Modelado. Hasta la fecha de este informe no se ha entrenado ningún modelo, no se ha aplicado ninguna técnica de balanceo de clases (como SMOTE), no se ha ejecutado ninguna partición de entrenamiento y prueba (train_test_split), no existen predicciones generadas por el sistema y no se ha calculado Recall, F1-Score ni ninguna otra métrica de clasificación. Todo ese trabajo corresponde a la Fase 4 y aún no ha comenzado.

Un aspecto central para comprender el estado actual del proyecto es que el conjunto de datos producido hasta el momento (54.742 filas, con 0 eventos de Account Takeover positivos) no debe interpretarse como el entregable final de la Fase 3. Este resultado constituye evidencia de que el pipeline de preparación funciona correctamente de extremo a extremo, pero el conjunto resultante no es

apto para entrenar un clasificador binario, por lo cual la fase permanece abierta hasta resolver la estrategia de muestreo que se discute en la sección 4.17.

4.3. Caracterización inicial del RBA Dataset

Antes de seleccionar la muestra de trabajo, se ejecutó una primera pasada completa sobre el RBA Dataset, procesado por lotes (chunks) para evitar el agotamiento de memoria, con un tamaño de lote de 500.000 registros (63 lotes en total). Los resultados reales de esta caracterización se resumen en la siguiente tabla.

Métrica	Valor
Eventos totales procesados	31.269.264
Usuarios distintos	4.304.857
Usuarios con ≥ 15 eventos (umbral mínimo)	177.084

Cabe aclarar que la documentación de referencia había estimado de forma aproximada unos 33 millones de eventos y cerca de 3.3 millones de usuarios, el archivo real difiere de esa estimación, especialmente en la cantidad de usuarios distintos, la diferencia no constituye una inconsistencia entre los datos de esta fase, sino la brecha esperable entre una estimación documental previa y la caracterización real del archivo, y se deja registrada aquí con fines de trazabilidad.

4.4. Selección del subconjunto de usuarios

La estrategia de muestreo activa hasta el momento es un muestreo aleatorio simple (implementado como `MuestreoAleatorioSimple`), definido como una selección aleatoria, reproducible y sin reemplazo, parametrizada con una semilla fija de reproducibilidad (`RANDOM_STATE = 42`), un tamaño de muestra de 2.000 usuarios (`N_USUARIOS`) y un mínimo de 15 eventos por usuario (`MIN_EVENTOS_USUARIO`).

Como resultado, se seleccionaron 2.000 usuarios de los 177.084 elegibles, todos verificados con al menos 15 eventos. La extracción de su historial completo de autenticación (y no solo un número fijo de filas por usuario) produjo 54.742 registros.

El hallazgo metodológico más relevante de esta etapa es que la muestra aleatoria resultante no contuvo ningún evento de Account Takeover. Dado que la prevalencia real del target en el RBA completo es de apenas 0,000451% a nivel de evento (ver sección 4.15), una muestra aleatoria simple de 2.000 usuarios tiene una probabilidad no despreciable de no capturar ningún caso positivo; se trata de un resultado estadísticamente esperable y no de una falla del componente de selección. Este hallazgo fue precisamente lo que motivó el diagnóstico de elegibilidad de usuarios ATO (sección 4.15) y la necesidad de evaluar una estrategia de muestreo distinta antes de poder cerrar esta fase.

4.5. Generación del maestro sintético de empleados

El componente `GeneradorEmpleados` produce exactamente 2.000 registros del maestro sintético de personal (`empleados.csv`), anclados a los identificadores de usuario (`User ID`) previamente seleccionados, con integridad referencial verificada al 100%. La reproducibilidad de esta generación está garantizada mediante semillas fijas tanto para la librería de datos sintéticos (`FAKER_SEED = 42`) como para el proceso de selección (`RANDOM_STATE = 42`).

El campo `Pais_Residencia` se genera directamente en código ISO2, en lugar del nombre del país en español, lo que constituye la representación canónica que permitirá compararlo más adelante contra el campo `ip_country_code` sin fricción de idioma. El campo `Ciudad_Base` se valida como coherente con `Pais_Residencia` en el 100% de los casos generados.

Es importante aclarar que los roles, turnos, país de residencia y estado de cuenta corresponden a distribuciones sintéticas declaradas explícitamente en el código del generador, y no deben interpretarse como estadísticas reales de personal hospitalario.

4.6. Enriquecimiento mediante IPinfo

El componente ResolutorIPinfo clasifica cada dirección IP del RBA como IPv4, IPv6 o inválida, y resuelve las direcciones IPv4 mediante una unión por intervalos (pd.merge_asof, dirección backward) contra los rangos publicados en el catálogo IPinfo, con una validación posterior que verifica que la IP se encuentre dentro del rango resuelto.

Métrica	Valor
IPs IPv4 únicas a resolver	16.438
IPs IPv4 resueltas	13.779
Tasa de resolución	83,82%

No se fuerza la resolución de las IPs no encontradas en el catálogo; estas quedan explícitamente como valores nulos. Las columnas provenientes de IPinfo se incorporan con el prefijo ip_ y en ningún caso sustituyen los campos originales Country, Region o City del RBA. El campo ip_country_code (código ISO2 nativo de IPinfo) es el que se utiliza para construir la variable country_mismatch; el campo ip_country_name se conserva únicamente como referencia legible y nunca se emplea para comparaciones geográficas.

Durante la ejecución real se documentó una corrección técnica relevante: se presentó un error de unión (MergeError) por incompatibilidad de tipos de dato,

ya que la columna `ip_int` se generaba como `float64` debido a la presencia de IPs inválidas o IPv6 en el RBA completo, mientras que las columnas `start_ip_int` y `end_ip_int` del catálogo `IPinfo` se generaban como `int64` al no existir entradas inválidas en dicho catálogo. La corrección consistió en forzar explícitamente el tipo `int64` en ambos lados de la unión, únicamente después de garantizar la ausencia de valores nulos en los subconjuntos que participan de ella. Esta corrección quedó preservada en el método `ResolutorIPinfo.resolver()` y está cubierta por una prueba de regresión dedicada (ver sección 4.13).

4.7. Tratamiento temporal y de variables de autenticación

4.7.1. Login Timestamp

Aunque la documentación oficial del RBA indicaba un formato numérico, los datos reales requerían un tratamiento como texto de fecha y hora. El sistema detectó y adaptó esta conversión automáticamente, validando un rango temporal consistente con el Dataset original (del 3 de febrero de 2020 al 28 de febrero de 2021).

4.7.2. Login Successful

se aplicó una normalización defensiva capaz de reconocer tanto valores booleanos como textuales, sin forzar los valores ambiguos a `False`. El resultado real de esta normalización fue de 46.143 eventos exitosos y 8.599 eventos fallidos, sin ningún valor no interpretable, por lo que no se documentaron casos de incertidumbre en esta corrida.

4.8. Ingeniería de características

A partir de las tres fuentes integradas se construyó un conjunto de variables de comportamiento orientadas a los dos vectores de ataque definidos en la Fase 1: fuerza bruta / credential stuffing y suplantación silenciosa (viaje imposible).

Feature	Representa	Resultado real
failed_attempts_15min / failed_attempts_1h	Fuerza bruta / credential stuffing: fallos previos en ventanas retrospectivas (closed="left", nunca incluye el evento actual)	media de 0,185 y 0,274 intentos fallidos previos, respectivamente
has_previous_login	Marca explícita (0/1) de si existe historial previo — evita que el missing semántico del primer evento se confunda con un valor real	2.000 usuarios en su primer evento; 52.742 registros con historial previo
distance_previous_km / required_speed_kmh / impossible_travel	Suplantación silenciosa vía Impossible Travel: distancia Haversine entre centroides ISO2 de país actual/anterior, velocidad requerida, y marca de anomalía si supera UMBRAL_VELOCIDAD_KMH=800 en menos de VENTANA_MAX_HORAS=12	cobertura de centroides geográficos de 15 de 59 países (25,42%); impossible_travel = 1 en 1 registro
is_outside_shift	Acceso fuera del turno asignado, respetando turnos que cruzan medianoche (ej. Nocturno 22:00→06:00)	33.787 registros fuera del turno asignado
country_mismatch	Comparación ISO2 vs. ISO2 entre Pais_Residencia e ip_country_code; NaN si falta cualquiera de los dos	43.754 registros en 1; 10.883 registros en NaN por falta de dato
inactive_account_success	Login exitoso en una cuenta marcada Inactivo	4.263 registros

Todas las ventanas retrospectivas se calculan ordenando los datos por User ID y por Login Timestamp de forma ascendente, garantizando que ninguna característica utilice información proveniente de eventos futuros respecto al evento que describe.

4.9. Validaciones de calidad

El componente de validación bloqueante (`validar_calidad_bloqueante`) verifica, como mínimo: la cantidad exacta de usuarios seleccionados, la integridad referencial entre fuentes, el número mínimo de eventos por usuario, el tipo de dato `datetime64` del campo Login Timestamp, el orden temporal correcto de los registros, la presencia de las columnas obligatorias, la existencia y no vacuidad de la variable objetivo, la ausencia de fechas implausibles, y dos verificaciones estructurales anti-fuga: que los registros sin historial previo (`has_previous_login = 0`) nunca tengan valores no nulos en `distance_previous_km` o `required_speed_kmh`, y que la variable `country_mismatch` no pueda ser no nula si `ip_country_code` es nula. En la ejecución real original del pipeline, todas las validaciones bloqueantes fueron aprobadas.

4.10. Control de fuga de información (target leakage)

El control de fuga de información no se apoya únicamente en la disciplina de codificación, sino en una regla estructural del propio pipeline: el método `PipelineFase03.ejecutar()` retira físicamente la columna `Is Account Takeover` del `DataFrame` inmediatamente después de la resolución de IP, y antes de invocar

cualquier función del módulo `features.py`. La columna se reincorpora únicamente después de que todas las características han sido construidas, justo antes de las etapas de validación y exportación. Mientras la columna no existe en el `DataFrame`, resulta físicamente imposible que una función de ingeniería de características la utilice.

Esta garantía fue verificada empíricamente mediante dos pruebas: una que baraja aleatoriamente los valores de `Is Account Takeover` y confirma que ninguna característica calculada cambia como consecuencia de ello, y otra que confirma que el código fuente de `features.py` no contiene ninguna mención textual del `target`.

Se establece además una distinción metodológica relevante: utilizar `Is Account Takeover` para construir una característica está prohibido en todos los casos, pues constituye fuga de información. En cambio, utilizar esa misma variable para decidir qué usuarios ingresan a la muestra (diseño de tipo caso-control) es metodológicamente válido y no constituye leakage, ya que solo determina qué filas entran al conjunto de datos y nunca qué valor toma una característica. No obstante, esta decisión introduce un muestreo condicionado al resultado que altera la prevalencia observada respecto al RBA completo, motivo por el cual debe declararse explícitamente si llegara a adoptarse (ver sección 4.17).

4.11. Arquitectura modular

El pipeline, originalmente concentrado en un único archivo, fue refactorizado hacia una arquitectura modular con el fin de cumplir con el requisito de trabajar con clases, métodos organizados, funciones y modularidad explícita. La organización resultante separa responsabilidades en módulos independientes para: configuración y constantes de dominio, utilidades de clasificación de IP, utilidades de conversión de marcas de tiempo, lectura y análisis del RBA, estrategias de muestreo, generación del maestro de empleados, resolución de IPinfo, ingeniería de características, validación de calidad, generación de diagnósticos, exportación del Dataset final y orquestación general del pipeline, además de un punto de entrada principal y un directorio de pruebas.

Las clases se mantuvieron deliberadamente reducidas para evitar sobreingeniería: solo existen donde hay un estado compartido genuino entre métodos o donde se requiere sustituibilidad por inyección de dependencias, como es el caso de la configuración del pipeline, el analizador del RBA, el resultado de muestreo, la estrategia de muestreo y sus implementaciones concretas, el generador de empleados, el resolutor de IPinfo y el orquestador del pipeline. Los módulos de características, validación, diagnóstico y exportación permanecen como funciones a nivel de módulo, y no como clases, porque cada uno expone un

único método público sin estado propio y sigue un orden de ejecución fijo, no intercambiable entre ellos.

4.12. Principios SOLID aplicados

En este informe se documentan únicamente los principios SOLID con aplicación real y demostrable en el código, evitando afirmaciones nominales sin sustento.

1. **Principio de responsabilidad única (SRP):** Cada módulo tiene una única razón para cambiar; por ejemplo, un cambio en la lógica de resolución de IP solo afecta al módulo correspondiente, y un cambio en una regla de negocio solo afecta al módulo de características.
2. **Principio de abierto/cerrado (OCP):** La interfaz de estrategia de muestreo permite incorporar una nueva estrategia (muestreo estratificado por target) sin modificar el orquestador del pipeline ni ninguna otra clase existente; basta con inyectar una implementación distinta.
3. **Principio de inversión de dependencias (DIP):** El orquestador del pipeline recibe la estrategia de muestreo ya construida desde afuera, en lugar de instanciar internamente una implementación concreta.

No se afirma la aplicación de los principios de segregación de interfaces (ISP) ni de sustitución de Liskov (LSP), dado que no existen múltiples interfaces

cliente-específicas que segregan, ni jerarquías de sustitución más allá de la única interfaz de estrategia de muestreo. Forzar la aplicación de esos principios constituiría una afirmación nominal y no una aplicación real.

4.13. Pruebas realizadas

Las pruebas se ejecutaron en un entorno de Google Colab utilizando los archivos reales de la corrida original (RBA muestreado, catálogo de país/ASN y maestro de empleados). En total se ejecutaron 12 pruebas, todas aprobadas, en 100,81 segundos. La cobertura de estas pruebas incluyó:

- Equivalencia extremo a extremo del pipeline modular frente al monolito, sobre datos reales.
- Reproducibilidad del maestro de empleados utilizando las mismas semillas.
- Equivalencia del maestro de empleados generado por la versión modular frente al monolito.
- Verificación de que Pais_Residencia se genera en código ISO2.
- Verificación de centroides geográficos en código ISO2, no en nombres en español.
- Verificación de country_mismatch como comparación ISO2 contra ISO2, con NaN cuando falta información.

- Verificación de `has_previous_login` y del forzado correcto de NaN en las variables de viaje imposible para el primer evento de cada usuario.
- Robustez de la ventana retrospectiva ante el caso límite de un único usuario en la muestra.
- Corrección del error de tipo de dato (`dtype`) en la unión por intervalos, reproduciendo el escenario real que originó el `MergeError`.
- Verificación de no fuga de información: barajar el target no modifica ninguna característica calculada.
- Verificación de que el módulo de características no menciona el target en su código fuente.
- Prueba de humo (smoke test) extremo a extremo con datos sintéticos, que verifica el correcto ensamblaje del pipeline modular.

4.14. Equivalencia entre pipeline legacy y el modular

Se realizó una comparación exhaustiva, y no limitada a una simple verificación de igualdad, entre el pipeline monolítico original y la arquitectura modular, ejecutando ambos sobre los mismos datos reales.

Dimensión	Resultado
Forma del dataset	Idéntica: 54.742 filas × 35 columnas en ambos casos
Columnas (nombres y orden)	Idénticas
Tipos de dato (dtypes)	Idénticos en las 35 columnas
Valores (comparación fila por fila)	Exitosa; idénticos en su totalidad
Nulos por columna	Idénticos
Distribución de características	Idéntica en las 9 características de comportamiento
Distribución del target	Idéntica

A partir de esta comparación se concluye que el refactor modular es funcionalmente equivalente al pipeline monolítico original para el Dataset real evaluado.

Se registró además una observación relevante, que no constituye una falla: se detectó una diferencia entre el archivo empleados.csv de la corrida histórica original y el regenerado posteriormente, específicamente en el campo Fecha_Ingreso, donde cada fecha difiere de la histórica por un desfase uniforme de 7 días en la totalidad de los registros inspeccionados. Este patrón de desfase

constante y no aleatorio es consistente con un cambio de versión de la librería Faker entre la corrida original y la corrida de verificación posterior, dado que la reproducibilidad de semilla de dicha librería está garantizada dentro de una misma versión, pero no necesariamente entre versiones distintas. Esta diferencia no proviene de una discrepancia entre el pipeline legacy y el modular, ya que ambos, ejecutados el mismo día bajo el mismo entorno, produjeron resultados idénticos entre sí, como se observa en la tabla anterior. Se documenta, por lo tanto, como una observación de entorno y no como una falla de equivalencia.

4.15. Diagnóstico de Account Takeover (ATO Diagnóstico de Account Takeover (ATO))

4.15.1. Diagnóstico 1: ejecutado, con resultados completos

Se ejecutó un diagnóstico independiente, de solo lectura y por lotes, sobre la totalidad del RBA (31.269.264 eventos), con el fin de caracterizar cuantitativamente la prevalencia real del target.

Métrica	Valor
Eventos con Is Account Takeover = True	141
Usuarios distintos con al menos 1 evento ATO	138
Usuarios ATO con ≥ 15 eventos totales	43

Usuarios ATO con menos de 15 eventos totales	95
Usuarios con exactamente 1 evento ATO	135
Usuarios con exactamente 2 eventos ATO	3
Prevalencia ATO por evento	0,000451%
Prevalencia ATO por usuario	0,003206%

Este diagnóstico confirma cuantitativamente el hallazgo descrito en la sección 4.4: la prevalencia real del target es extremadamente baja, y 95 de los 138 usuarios con al menos un evento ATO ni siquiera alcanzan el umbral mínimo de historial (15 eventos) que exige el pipeline actual.

4.15.2. Diagnóstico 2: script entregado, ejecución pendiente de reporte

Se diseñó y entregó un segundo script independiente de solo lectura, orientado a caracterizar en detalle a los 43 usuarios ATO elegibles: sus eventos totales y ATO exactos, su distribución estadística completa, una tabla usuario por usuario, y una estimación de la prevalencia resultante de una muestra hipotética compuesta por esos 43 usuarios ATO más el resto de los usuarios no-ATO elegibles. Este script aún no ha sido ejecutado sobre el RBA real, o su resultado

todavía no ha sido reportado. En consecuencia, en este documento no se presenta ni se infiere ningún número proveniente de este diagnóstico; su resultado constituye un insumo pendiente para la decisión descrita en la sección 4.17.

4.16. Situación actual de la fase

Trabajo realizado y validado:

- Pipeline completo ejecutado de extremo a extremo sobre datos reales (RBA de 31,27 millones de eventos, catálogo IPinfo real y maestro de empleados sintético).
- Las ocho etapas del pipeline (análisis del RBA, selección de usuarios, extracción de historial, generación de empleados, resolución de IP, ingeniería de características, validación y exportación) funcionan correctamente y produjeron un Dataset de 54.742 filas por 35 columnas, con todas las validaciones bloqueantes aprobadas.
- Refactor arquitectónico completo, con 12 de 12 pruebas aprobadas y equivalencia exacta demostrada frente al pipeline monolítico sobre datos reales.
- Barrera estructural anti-leakage implementada y verificada empíricamente.

- Corrección del error de tipo de dato en la unión por intervalos, aplicada y cubierta por una prueba de regresión.

Diagnósticos realizados:

- Diagnóstico 1 sobre el RBA completo: prevalencia real del target confirmada (141 eventos en 138 usuarios), con cuantificación exacta de cuántos usuarios ATO son utilizables bajo el criterio de elegibilidad actual (43 de 138).
- Diagnóstico 2: diseñado y entregado, pendiente de ejecución o de reporte de resultados.

Trabajo pendiente:

1. Ejecutar o completar el análisis adicional de los usuarios ATO elegibles (Diagnóstico 2), en caso de no disponerse aún de sus resultados.
2. Definir la estrategia final de muestreo (sección 4.17), con base en los resultados de ambos diagnósticos.
3. Implementar la estrategia seleccionada, posiblemente el muestreo estratificado por target, hoy definido únicamente como interfaz pendiente.
4. Ejecutar nuevamente el pipeline completo con la estrategia de muestreo definitiva.

5. Verificar la distribución final del target en el nuevo Dataset resultante.
6. Realizar las validaciones finales sobre ese nuevo Dataset antes de declarar cerrada la Fase 3.
1. Ejecutar o completar el análisis adicional de los usuarios ATO elegibles (Diagnóstico 2), en caso de no disponerse aún de sus resultados.
2. Definir la estrategia final de muestreo (sección 4.17), con base en los resultados de ambos diagnósticos.
3. Implementar la estrategia seleccionada, posiblemente el muestreo estratificado por target, hoy definido únicamente como interfaz pendiente.
4. Ejecutar nuevamente el pipeline completo con la estrategia de muestreo definitiva.
5. Verificar la distribución final del target en el nuevo Dataset resultante.
6. Realizar las validaciones finales sobre ese nuevo Dataset antes de declarar cerrada la Fase 3.

4.17. Decisiones pendientes

La decisión central que permanece pendiente es el diseño definitivo de la estrategia de muestreo. Las alternativas actualmente en evaluación son las siguientes:

- **Mantener el muestreo aleatorio simple:** es metodológicamente sencillo, pero ya demostró en la sección 4.4 que puede producir un Dataset sin ningún caso positivo, lo cual lo hace inutilizable para entrenar un clasificador binario en la Fase 4.
- **Adoptar un muestreo estratificado por target (diseño caso-control):** consiste en incluir deliberadamente a los usuarios ATO elegibles y completar el resto de la muestra con usuarios no-ATO. Esto no constituye fuga de información, de acuerdo con la distinción metodológica presentada en la sección 4.10, pero sí introduce un sesgo de prevalencia deliberado que debe documentarse explícitamente si se adopta, ya que la prevalencia resultante en el Dataset final no representará la prevalencia real del RBA completo.

Esta decisión no se ha tomado todavía. El muestreo estratificado por target existe hoy únicamente como una clase con la interfaz definida, bajo el mismo contrato que el muestreo aleatorio simple, pero su método de selección lanza intencionalmente una excepción de método no implementado, a la espera de esta decisión y del resultado del Diagnóstico 2.

4.18. Conclusiones parciales

El pipeline de preparación de datos desarrollado hasta la fecha es técnicamente sólido: procesa correctamente el RBA completo por lotes sin agotar memoria, integra las tres fuentes de información con trazabilidad, construye las características de comportamiento sin fuga de información del target ni del futuro, y su refactor hacia una arquitectura modular es funcionalmente equivalente al monolito original, con evidencia de prueba sobre datos reales.

Sin embargo, el Dataset que este pipeline produce actualmente (54.742 filas, con 0 eventos de Account Takeover) no es apto para avanzar a la Fase 4 tal como está, dado que un clasificador no puede entrenarse ni evaluarse sin ejemplos de la clase positiva. Por esta razón, la Fase 3 se declara explícitamente en estado de avance y no como una fase cerrada, hasta que se resuelva la estrategia de muestreo descrita en la sección 4.17 y se regenere el Dataset final a partir de ella. La Fase 4 no podrá comenzar mientras esta condición no se cumpla.